

Remote WhatsApp-to-Agent Command Loop

Standalone technical deep-dive dossier

Remote WhatsApp-to-Agent Command Loop

Ich wollte von unterwegs mit meinem Handy Arbeit an meinen Laptop uebergeben koennen, ohne daraus eine gefaehrliche direkte Shell zu machen. Die WhatsApp-Nachricht sollte erst verstanden, in einen Arbeitsauftrag uebersetzt, ausgefuehrt, bewertet und dann sauber zurueckgemeldet werden.

- This is the clearest Secure AI signal: remote natural-language instructions became structured work orders, then passed through tool execution and evaluation before a user-facing reply.
- Persoenlicher Prototyp bzw. entwickeltes System, keine Behauptung eines produktionsgehaerteten Sicherheitsprodukts.

Was ich mir dabei gedacht habe

Was ich mir dabei gedacht habe, war einfach, aber technisch anspruchsvoll: Ich wollte nicht am Laptop sitzen muessen und trotzdem sinnvoll Arbeit an ihn uebergeben koennen, ohne mein Handy zu einer blinden Remote-Shell zu machen. Der interessante Teil war die Vertrauensgrenze. Eine Nachricht musste erst zum Arbeitsauftrag werden, ausgefuehrt und danach bewertet werden, bevor sie zu mir zurueckkommt.

Was ich gebaut habe

- Ich habe Fernzugriff als Autoritaets- und Sicherheitsproblem behandelt, nicht nur als Komfortfunktion.
- Ich habe die Front-Agenten-Schicht von der tool-reichen Ausfuehrungsschicht getrennt.
- Ich habe mobile Sprache/Chat in strukturierte Arbeit mit Erfolgskriterien uebersetzt.

Mechanik im Detail

- Der wertvolle Teil ist nicht WhatsApp selbst. WhatsApp ist nur der reibungsarme Eingang. Der harte Teil ist die Übersetzung: eine lockere Nachricht vom Handy wird zu einem strukturierten Arbeitsauftrag mit Ziel, Komplexität, Modellhinweis und Erfolgskriterien.
- Das Dual-Brain-Muster trennt die Rolle, die versteht und bewertet, von der Rolle, die mit Tools ausführt. Dadurch wird eine Handy-Nachricht nicht zu einem ungeprüften Direktbefehl.
- Die Antwort kommt bewusst erst nach der Bewertung zurück. Das ist näher an Supervisor/Executor als an einem normalen Chatbot.

Architektur

- WhatsApp oder Audio kommt in der OpenClaw-Schicht an.
- Ein Watcher normalisiert Ereignisse, dedupliziert Nachrichten und behandelt Medien.
- MiguelAgent macht daraus Ziel, Komplexitaet, Arbeitsauftrag, Erfolgskriterien und Modell-Hinweis.
- Die Ausfuehrungsseite nutzt Miguel/EXOVIUM-Tools und Modellrouting.

- Eine Qualitätschleife prüft, ob das Ergebnis wirklich fertig ist.
- Erst danach wird die Antwort wieder an WhatsApp geschickt.

Evidenzcluster

- Workflow-Notizen zu WhatsApp-Event-Erkennung, Audio-Transkription, strukturierten Arbeitsaufträgen, Modellhinweisen und Quality-Loop-Schwellen.
- Pipeline-Notizen zur Kette WhatsApp -> Gateway -> Watcher -> MiguelAgent -> Ausführung/Bewertung/Formatierung -> Antwort.
- Python-Watcher- und MiguelAgent-Module mit Event-Parsing, Medienhandling, Deduplication, Arbeitsauftragsausführung, Evaluator-Loop und Antwortformatierung.
- Entscheidungsnotizen zu schneller Bestätigung, Smart Routing und erfolgreichen End-to-End-Tests.

Claim-zu-Evidenz-Karte

Die öffentliche Version soll stark wirken, weil sie begrenzt ist, nicht weil sie übertreibt.

Claim	Evidenz	Grenze
This is the clearest Secure AI signal: remote natural-language instructions became structured work orders, then passed through tool execution and evaluation before a user-facing reply.	Workflow-Notizen zu WhatsApp-Event-Erkennung, Audio-Transkription, strukturierten Arbeitsaufträgen, Modellhinweisen und Quality-Loop-Schwellen.; Pipeline-Notizen zur Kette WhatsApp -> Gateway -> Watcher -> MiguelAgent -> Ausführung/Bewertung/Formatierung -> Antwort.	Persoenlicher Prototyp bzw. entwickeltes System, keine Behauptung eines produktionsgehaerteten Sicherheitsprodukts.
Die Arbeit ist wertvoll, weil sie Mechanik zeigt, nicht nur Oberfläche.	WhatsApp oder Audio kommt in der OpenClaw-Schicht an.; Ein Watcher normalisiert Ereignisse, dedupliziert Nachrichten und behandelt Medien.	Frische öffentliche Demos oder Benchmarks wären die nächste Beweisschicht.

Senior-Level-Signal

This is the clearest Secure AI signal: remote natural-language instructions became structured work orders, then passed through tool execution and evaluation before a user-facing reply.

- Authority Boundary Thinking: Der Remote-Kanal ist bequem, aber das System behandelt ihn als riskante Kontrollfläche.
- Operatives Denken: schnelle Bestätigung, Deduplication, Medienhandling und finale Rückmeldung sind getrennte Fehlerpunkte.
- Evaluator-Loop-Intuition: Das System führt nicht nur aus, sondern prüft, ob das Ergebnis den ursprünglichen Auftrag erfüllt.

Skeptische Reviewer-Fragen

- Was ist hier wirklich gebaut und was ist noch Design? Antwort: Status und Grenze stehen im Dossier direkt beim Fall Remote WhatsApp-to-Agent Command Loop.
- Welche private Evidenz wurde bewusst nicht veröffentlicht? Antwort: lokale Pfade, Credentials, private Kanaldetails und vertrauliche Rohtexte bleiben draußen.

- Warum ist das relevant? Antwort: Der Fall zeigt einen wiederverwendbaren Baustein für Agenten, Tool-Nutzung, Memory, Routing, Validierung oder High-Stakes-Governance.
- Was wäre der nächste belastbare Beweis? Antwort: synthetische Demo, Audit Trace, Benchmark oder externe Review, je nach Fall.

Lernpunkte und Grenzen

Persoenlicher Prototyp bzw. entwickeltes System, keine Behauptung eines produktionsgehaerteten Sicherheitsprodukts.

- Schnell bestaetigen, langsam und kontrolliert arbeiten, erst nach Bewertung antworten.
- Remote-Steuerung braucht Deduplikation, Unterbrechbarkeit, Fortschritt und Audit-Spuren.
- Private Kanal-IDs und Zugangsdaten gehoeren nie in ein oeffentliches Portfolio.

Nächste Härtung / nächster Projektschritt

- Oeffentlichen Demo-Modus mit synthetischen Daten bauen.
- Befehle nach Risiko und Bestaetigungsbedarf klassifizieren.
- Tool-Aufrufe, Modellwahl und Bewertung als sichere Audit-Events speichern.
- Einen öffentlichen synthetischen Demo-Flow bauen, in dem ein Mock-WhatsApp-Event zu einem Arbeitsauftrag wird, ein Fake-Executor läuft und ein Evaluator freigibt oder Nacharbeit verlangt.
- Jeden Übergang loggen: Eingang, Normalisierung, Work Order, Tool Plan, Executor Result, Evaluator Result und Antwort.
- Permission-Klassen für Read-only, Write, Shell, Netzwerk und irreversible Aktionen hinzufügen.