

Memory, Vault, CASS und Smart Memory MCP

Eigenständiges technisches Deep-Dive-Dossier

Memory, Vault, CASS und Smart Memory MCP

Ich wollte Agenten nicht nur grössere Kontextfenster geben, sondern echtes Arbeitsgedächtnis: roh, zusammengefasst, prozedural, widerspruchsbewusst, veraltetheitsbewusst und wieder abrufbar.

- Zeigt Verständnis für Agenten-Zuverlässigkeit: Memory ist nicht nur Kontext, sondern Provenance, Widerspruchsbehandlung, Staleness, Zugriffshistorie und prozedurales Lernen.
- Praktische Memory-Infrastruktur, keine Behauptung menschenähnlichen Bewusstseins.

Was ich mir dabei gedacht habe

Die Memory-Arbeit entstand aus der Beobachtung, dass Agenten nicht nur mehr Kontext brauchen. Sie brauchen Memory-Hygiene: Rohfakten, Zusammenfassungen, prozedurales Lernen, Widersprüche, Veraltetheit und Provenance.

Was ich gebaut habe

- Ich habe Memory als Governance-Problem behandelt, nicht als Notizablage.
- Ich habe Rohdaten, Zusammenfassungen und Regeln getrennt.
- Ich habe Widerspruch, Veraltung und Herkunft als zentrale Risiken erkannt.

Mechanik im Detail

- Die Memory-Arbeit ist am stärksten, wenn sie als Reliability Infrastructure erklärt wird. Sie trennt rohe episodische Records von komprimiertem Working Memory und prozeduralen Regeln.
- Broker/Broadcast reagieren auf Modul-Isolation: wichtige Fakten, zentrale Notizen und Widersprüche müssen zwischen Subsystemen wandern können.
- Vault Watcher und Smart Memory MCP machen Memory zu mehr als einem Ordner: Indexierung, Recency, Usefulness, Access-Metadaten, Graph-Kontext und Stale-Information-Handling.

Architektur

- CASS trennt episodische Rohdaten, Arbeitsgedächtnis und prozedurale Regeln.
- Memory Broker verteilt wichtige Fakten und markiert leichte Widersprüche.
- Vault Watcher denkt Dateiaenderungen, inkrementelles Indexing, Graph Updates und Staleness.
- Smart Memory MCP macht Lernen, Recall, Stats, Muster und Vorschläge als lokale Tools verfügbar.

Evidenzcluster

- Memory Broker mit Broadcast-Schema, Write Logs, Weight/Centrality Scoring und leichter Widerspruchserkennung.
- CASS-Pipeline mit episodischem Rohgedächtnis, Working Summaries, prozeduralen Regeln, Confidence, Decay und SQLite-Persistenz.

- Vault-Watcher-Design mit File-Change-Detection, inkrementeller Indexierung, Graph Updates, Staleness Propagation und Forgetting Score.
- Smart Memory MCP mit Learn/Recall/Stats/Pattern/Suggestion-Tools und Retrieval-Metadaten.

Claim-zu-Evidenz-Karte

Die öffentliche Version soll stark wirken, weil sie begrenzt ist, nicht weil sie übertreibt.

Claim	Evidenz	Grenze
Zeigt Verständnis für Agenten-Zuverlässigkeit: Memory ist nicht nur Kontext, sondern Provenance, Widerspruchsbehandlung, Staleness, Zugriffshistorie und prozedurales Lernen.	Memory Broker mit Broadcast-Schema, Write Logs, Weight/Centrality Scoring und leichter Widerspruchserkennung.; CASS-Pipeline mit episodischem Rohgedächtnis, Working Summaries, prozeduralen Regeln, Confidence, Decay und SQLite-Persistenz.	Praktische Memory-Infrastruktur, keine Behauptung menschenähnlichen Bewusstseins.
Die Arbeit ist wertvoll, weil sie Mechanik zeigt, nicht nur Oberfläche.	CASS trennt episodische Rohdaten, Arbeitsgedächtnis und prozedurale Regeln.; Memory Broker verteilt wichtige Fakten und markiert leichte Widersprüche.	Frische öffentliche Demos oder Benchmarks wären die nächste Beweisschicht.

Senior-Level-Signal

Zeigt Verständnis für Agenten-Zuverlässigkeit: Memory ist nicht nur Kontext, sondern Provenance, Widerspruchsbehandlung, Staleness, Zugriffshistorie und prozedurales Lernen.

- Kontextintegrität: Zusammenfassungen sind nützlich, aber gefährlich, wenn sie Rohbelege ersetzen.
- Widerspruchsbehandlung: Konflikte werden nicht einfach überschrieben.
- Agent-Safety-Relevanz: Stale Memory kann zu falschen Aktionen, falscher Sicherheit und Zielabweichung führen.

Skeptische Reviewer-Fragen

- Was ist hier wirklich gebaut und was ist noch Design? Antwort: Status und Grenze stehen im Dossier direkt beim Fall Memory, Vault, CASS und Smart Memory MCP.
- Welche private Evidenz wurde bewusst nicht veröffentlicht? Antwort: lokale Pfade, Credentials, private Kanaldetails und vertrauliche Rohtexte bleiben draußen.
- Warum ist das relevant? Antwort: Der Fall zeigt einen wiederverwendbaren Baustein für Agenten, Tool-Nutzung, Memory, Routing, Validierung oder High-Stakes-Governance.
- Was wäre der nächste belastbare Beweis? Antwort: synthetische Demo, Audit Trace, Benchmark oder externe Review, je nach Fall.

Lernpunkte und Grenzen

Praktische Memory-Infrastruktur, keine Behauptung menschenähnlichen Bewusstseins.

- Agenten werden gefährlich oder nutzlos, wenn sie veraltete Zusammenfassungen für Wahrheit halten.
- Widersprüche sollen erhalten und sichtbar gemacht werden, nicht still ueberschrieben.
- Retrieval braucht mehr als Textähnlichkeit: Nuetzlichkeit, Zeit und Vertrauen zaehlen.

Nächste Härtung / nächster Projektschritt

- Synthetische Public-Memory-Demo bauen.
- Retrieval und Widerspruchserkennung auf nicht-privaten Daten benchmarken.
- Memory-Provenance in Agentenantworten anzeigen.
- Einen synthetischen Vault mit absichtlichen Widersprüchen und veralteten Fakten bauen.
- Zeigen, wie der Agent Episoden, Working Summaries und prozedurale Regeln mit Provenance abruft.
- Retrieval-Qualität und Widerspruchserkennung auf öffentlichen Daten benchmarken.