

Multi-model cascade router

Einzelnes druckfertiges Themen-Dossier.

Erstellt 2026-06-17

Warum ich es gebaut habe

Ich wollte nicht alles blind durch ein Modell schicken. Der Router behandelt Modelle als Ressourcen mit Stärken, Kosten, Quoten, Ausfällen, Qualität und Datenschutzkontext.

Architektur und Evidenz

Grenze: Exakte Kostenersparnis nur dann behaupten, wenn neue Messlogs sie belegen.

- Task-Strategien wählen schnell, hochwertig, gratis, lokal, Code, kreativ oder bulk.
- Lokale Modelle und kostenlose APIs werden dort bevorzugt, wo es sinnvoll ist.
- Quoten, Cooldowns und Ausfälle blockieren schlechte Routen.
- Qualitätsgates entscheiden, ob eskaliert wird.
- Mehrere freie Modelle können gegeneinander laufen, langsamere Calls werden abgebrochen.

Was ich zeigen kann

- Ich habe Modellwahl als Governance-System behandelt, nicht als Geschmacksfrage.
- Ich habe Kosten, Latenz, Quoten, Qualität und Fallbacks im selben System gedacht.
- Ich habe lokale und API-basierte Modelle in einer Routing-Logik verbunden.
- Ein guter Agent muss elegant schlechter werden können, wenn Modelle ausfallen.
- Qualitätsgates sollten Eskalation auslösen, nicht Modell-Prestige.
- Outcome-Logging ist der Anfang empirischer Modell-Governance.
- Frische Benchmarks über repräsentative Aufgabenklassen laufen lassen.
- Aggregierte Kosten/Latenz/Qualität ohne Geheimnisse veröffentlichen.
- Policy-Labels für privat, öffentlich, billig, schnell und hochriskant einführen.